統計模組

從回測輸出到可以檢驗的結論

架構是框架，domain/statistics 是主體。

草稿 · 2026 年 11 月。統計程式都還在 PR 上，尚未合併到 main 。

閱讀路線

章節	主題	內容
01	架構：統計模組的位置	四層分工、為何只在 domain 、和績效管線的界線
02	統計模組	七個公開模組各回答什麼問題，以及怎麼選
03	現況與邊界	PR 拆分、介面缺口、兩個 issue 與修不掉的限制

01　架構：統計模組的位置

四層分工沿用主線架構；這一章只補統計模組需要的部分。

四層分工

層	位置	和統計模組的關係
MCP	`mcp/server.py` 、 `mcp/tools/` 、 `mcp/workers/`	協定轉換與背景工作；沒有匯入統計模組
Application	`app/`	協調策略、計畫、工作與結果查詢；沒有匯入統計模組
Domain	`domain/`	策略、回測、績效與排名邏輯；**統計模組加在這裡**
Adapters	`adapters/`	SQLite 、檔案、程序、 CLI 與 Dashboard ；沒有匯入統計模組

模組責任、訊號流程與 MCP 工具分組見介紹簡報的「01 系統架構」，這裡不重複。

為什麼統計模組只在 domain

- **輸入由呼叫端提供**：權益曲線、時間戳、交易紀錄、報酬序列或試驗列，都以參數傳入
- **不讀 run 、 artifact 或快取**：各模組的 docstring 都寫明這一點
- **只依賴計算套件**：匯入只有標準函式庫、 NumPy 、 pandas ，以及 bootstrap 用的 `arch`
- **可以交叉核對引擎**： `performance` 不讀引擎的 `metrics` ，只從原始輸出重算

主線架構提醒 domain 並非全是純計算（ crawlers 、 ML stores 會做 I/O ）；統計模組不做 I/O 。

和主線績效管線的界線

	主線績效管線	統計模組
資料來源	引擎觀察值，保存為 performance artifacts	呼叫端傳入的序列與紀錄
無風險利率	`risk_free_rate` 可設定	一律為零
`max_drawdown`	K 棒層級的比例	金額；比例另見 `max_drawdown_pct`
交易統計	已平倉交易	所有提供的紀錄
保存與查詢	發佈、 MCP 查詢、排行榜	不保存，未接入發佈或 MCP

同名欄位不能互相套用。

介紹簡報引用的架構版本之後的變化

介紹簡報的架構章引用 `9e502ce`（2026-11-07）。到 main `ad2fb75` 有 136 個 commit，其中 6 個修改 ARCHITECTURE.md（+31／−5）。

變化	章節
新增 `tooling/environment.py`、`tooling/llm_check.py`	Repository 開發工具
CLI 改稱「直接回測 CLI」；`tradingdev-codex` 對話入口走 MCP 流程	研究需求、執行回測
`ArtifactService.read_download` 與 MCP `ArtifactDownloads` 的短效網址	保存與查詢結果
新增「可見對話紀錄」（`ConversationService`）	新章節

四層的責任表沒有變。`domain/statistics` 那一列只在 #209 的分支上，main 還沒有。

02　統計模組

七個公開模組、兩個私有模組；每頁回答「它回答什麼問題」。

模組地圖

模組	回答的問題	所在 PR
`periods`	權益曲線怎麼切成日和月	#206
`performance`	從原始輸出重算，這次回測表現如何	#209
`breakeven`	成本吃掉多少、勝率夠不夠	#207
`sharpe`	這個 Sharpe 可信嗎、挑出來的還算嗎	#209
`comparison`	A 真的比 B 好嗎	第 5 包，尚未開 PR
`plateau`	最佳參數是高原還是尖峰	#208
`benchmark`	相對買進持有多了什麼	第 5 包，尚未開 PR

私有的 `_validation`、`_scaling` 在 #206；`comparison`、`benchmark` 依賴 `sharpe` 與 `periods`。

`periods`：權益曲線怎麼切成日和月

問題：引擎給的是逐根 K 棒的權益；Sharpe 和配對比較需要日或月報酬。

- 期間邊界一律是 UTC 日曆；naive 時間戳視為 UTC，帶時區的先轉成 UTC
- 每個觀測歸入時間戳標籤所在的期間：以開盤時間標記的 23:00 小時棒歸當天
- 沒有觀測的期間直接省略，不補零（週末、資料缺口）
- 拒絕數字時間戳：數字沒有單位，`1_704_067_200` 會被當成奈秒
- 報酬需要權益全為正；從零起算的累積損益曲線沒有報酬基礎

入口：`period_returns`、`period_pnl`、`period_closing_equity`、`to_utc_index`

`performance`：從原始輸出重算一次績效

問題：不看引擎的 `metrics`，只用權益、時間戳和交易紀錄，這次回測表現如何？

類別	`PerformanceSummary` 欄位
報酬	`total_pnl`、`total_return`
回撤	`max_drawdown`（金額）、`max_drawdown_pct`
波動	`daily_pnl_std`、`monthly_pnl_std`（金額，`ddof=1`）
風險調整	`sharpe_ratio`：日報酬，乘 `sqrt(periods_per_year)`
交易	筆數、勝負、`win_rate`、`profit_factor`

沒有年化報酬與報酬率波動欄位。`periods_per_year` 預設 365；權益不全為正時，報酬類欄位為 `None`。

`breakeven`：成本吃掉多少，勝率還夠不夠

問題：照這個盈虧比，勝率要多高才打平？交易成本占多少？

- 打平勝率 `p* = L / (W + L)`；`win_rate_edge` 是實際勝率減 `p*`，只計有輸贏的交易
- 周轉計入進出兩腿的名目金額；未平倉交易只計進場腿
- 成本是 `fee` 欄位加總，得出 `cost_per_turnover`；有 `capital` 時另算 `annual_cost_drag`
- 評估期間由呼叫端給 `start`、`end`，一年以 365.25 天計

限制：引擎若把成本併入 `net_pnl` 而沒寫進 `fee`，這裡會低估成本。

`sharpe`（一）：這個 Sharpe 有多不確定

問題： Sharpe 是點估計；換一段樣本，它可能差多少？

- `sharpe_ratio`：平均除以樣本標準差（`ddof=1`），無風險利率為零，乘 `sqrt(periods_per_year)`
- `sharpe_interval_outcome`： stationary bootstrap 百分位區間，預設 1000 次重抽、95%
- 區塊長度取報酬與報酬平方兩個自動估計的較大者，保留波動聚集
- 至少 `MIN_BOOTSTRAP_OBSERVATIONS` = 20 期；一年的月報酬一定不夠，`sharpe_interval_outcome` 回傳 `IntervalUnavailable` 說明原因

限制：自動區塊長度不保證名目覆蓋率；平方根年化不消除頻率差異，只比較同頻率的比率。

`sharpe`（二）：是真的嗎？從 N 個裡挑最好的還算嗎？

函式	回答	比較的門檻
`probabilistic_sharpe_ratio`（PSR）	真實 Sharpe 超過基準的機率	呼叫端給的 `benchmark_sr`，每期單位
`deflated_sharpe_ratio`（DSR）	挑出的最佳者，贏得過純運氣嗎	N 個無技能試驗的期望最大 Sharpe

- PSR 計入偏態與峰態，但假設報酬獨立，沒有序列相關項；DSR 沿用這個假設
- `n_trials` 必須含失敗、被丟掉的試驗；只傳存活數會修正不足，而且不報錯
- 網格試驗高度相關，對門檻有兩個相反的效果，淨方向未知

`comparison`：A 真的比 B 好嗎

問題：兩個策略跑在同一段行情上，差距是真的還是雜訊？

- 同一行情的策略共享衝擊；差的變異數是 `var(A) + var(B) − 2 cov(A, B)`
- `difference_interval`：先對齊共同期間，以同一組區塊索引重抽 A 與 B，回傳差、區間與 p 值
- 區塊長度由差的 jackknife influence 估計，不用 A、B 各自的
- 個別區間不重疊代表差異顯著；重疊不代表不顯著
- 預設 2000 次重抽；共同期間至少 20 期

只比較樣本外報酬。期間、標的或成本假設不同的策略不可比，統計修不了。

`plateau`：穩定高原還是運氣好的尖峰

問題：最佳參數旁邊的參數也表現好嗎？

- 鄰域用網格索引的 Chebyshev 距離，`DEFAULT_RADIUS` = 1 ，不用原始參數距離
- 平台分數是鄰居的平均指標，不含自己；孤立尖峰拿不到自己的分數
- 主要統計 `metric_gap` ：最佳試驗與平台最佳試驗的指標差； `spikiness` 為次要
- 失敗試驗留在軸上成為缺點； `trials_from_metrics` 回報 `dropped_count`
- 超過 `MAX_LOCAL_DIMENSIONS` = 3 個參數時鄰域不再局部，標記 `dimension_warning`

限制：整個參數區擬合同一種行情時會出現假高原，不能取代樣本外驗證。

`benchmark`：相對買進持有多了什麼

問題：策略相對於單純持有標的，多出了什麼？和它怎麼一起變動？

- `buy_and_hold_returns`：用呼叫端給的價格建買進持有報酬，不計成本
- `compare_to_benchmark`：beta、alpha、主動報酬、追蹤誤差、資訊比率、上下行捕獲率
- 「贏不贏買進持有」本身是 Sharpe 差，交給 `comparison.difference_interval`
- 交易同一標的時，beta 量的是平均淨曝險，不是系統風險

名稱：「超額報酬」保留給總報酬差；每期差的年化平均叫 `active_return_annualised`。這不是產品基準（`domain/benchmark.py` 的 `BENCHMARKS`）。

為什麼需要 `_validation` 和 `_scaling`

模組	要防的問題	做法
`_validation`	型別註記在執行時不強制： `True` 會變 1.0 ， `"0.01"` 會變 1%	拒絕布林、字串與其他物件；計數與 `seed` 須為內建 `int`
`_scaling`	四階動差在偏差約 `1e77` 時溢位；離散極小時平方下溢	幅度超過 `2**60` 或離散小於 `2**-60` 時，以 2 的冪次縮放

- `_validation` 對不支援的型別報 `ValueError` ，不默默轉成數字； NumPy 轉換失敗等錯誤仍照原樣拋出
- `_scaling` 對正常浮點數是精確縮放，但不保證統計量有限； `sharpe` 、 `plateau` 使用它

怎麼選：從問題到方法

想回答的問題	用這個	輸入要求
Sharpe 有多不確定	`sharpe_interval_outcome`	至少 20 期報酬
Sharpe 是否大於某個基準	`probabilistic_sharpe_ratio`	每期單位的基準
從 N 次試驗挑出的最佳者	`deflated_sharpe_ratio`	全部試驗數，含失敗
A 是否比 B 好	`difference_interval`	同一行情的樣本外報酬
最佳參數是否穩定	`plateau_summary`	完整網格列，含失敗
打平勝率與成本	`summarize_breakeven`	交易紀錄與評估起訖
相對持有的共同變動	`compare_to_benchmark`	同一組 K 棒、同頻率

三條不可混用的規則

1. **DSR 和 Bonferroni 不套在同一個數字上。** DSR 修正 Sharpe 家族（回測與最佳化試驗）；排行榜的 `required_t_stat` 以 Bonferroni 修正 IC t 統計量。兩者回答的問題、候選母體與獨立性假設都不同；並列時標明指標、修正方法與母體。
2. **樣本內序列不做配對比較。** 調過參數的樣本內報酬，比的是誰過擬合得更徹底，不是誰更好。
3. **門檻掃描不是參數曲面。** 每個門檻存成一個候選；`parameter_axes` 只含 horizon 、 IC window 與 quantile 數，曲面的警語與平台分析不適用。

03　現況與邊界

統計程式都還在 PR 上；main 沒有 domain/statistics。

拆分狀態

PR	分支	內容	狀態
#205	`docs/readme-final-evaluation-data`	README：保留最終評估資料的建議	open
#206	`stats/1-foundation`	`_validation`、`_scaling`、`periods`	open
#207	`stats/2-breakeven`	`breakeven`	open
#208	`stats/3-plateau`	`plateau`	open
#209	`stats/4-sharpe`	`sharpe`、`performance`，新增 `arch`	open
—	`stats/5-comparison`	`comparison`、`benchmark`	尚未開 PR

第 5 包的基底是 `b62ac97`，還不含 #209 目前的 head。#38 仍 open。

為什麼拆

- **審查負擔**：2026-10-27 會議認為 #38 太大，難以審查（32 個檔案，+9404 ／− 3）
- **依賴決定基底**：第 1 包不依賴其他統計模組；2、3、4 依賴 1；5 依賴 4 與 1
- **合併順序**：#206 → #207、#208、#209 不限順序 → 第 5 包
- **程式不改寫**：程式與測試從 `feat/stats-py314` 逐檔複製；#38 多出的是文件

介面上還缺的東西

統計模組要的輸入，和 main 保存的 `ScopeObservations` 對不上：

統計模組需要	main `ad2fb75` 的現況
`periods_per_year`：有限正數	不在 `ScopeObservations`；在 `BacktestConfig`，可為 `None`，預設 `None`
`equity_curve`：每個元素都是有限數字	型別是 `list[float or None]`，元素可為 `None`
`timestamps`：必填、嚴格遞增	型別是 `list[str] or None`，整個欄位可為 `None`

統計模組遇到 `None` 會報錯，不猜值；但 `summarize_performance` 省略 `periods_per_year` 時會用 365。

#189 ：搜尋規模沒有跟著代表結果

- 跨策略排名時，每個策略只派一組代表結果；最佳化 run 的預設 scope 是 `test`
- `RunCandidate` 沒有欄位說明這組參數是從多少組選出來的
- **擋住的是 DSR**：`deflated_sharpe_ratio` 需要 `n_trials` 和試驗 Sharpe 的離散度，兩者在選代表結果時就丟了
- **資料其實存在**：最佳化 run 的 performance bundle 保存每組的 `trial/{index}/train` scope

issue 自己寫明：記下搜尋規模只讓選擇幅度可以稽核，不建立 holdout 。

#190 ：分不出訊號是誰算的

- `evaluate_prediction`（後端用模型算訊號）和 `evaluate_signal`（呼叫端提供序列）寫出形狀相同的紀錄
- 帶 `model_id` 時，`training_dataset_id` 都來自 artifact ，與序列是誰算的無關
- **擋住的是配對比較的資格判斷**：帶 `model_id` 的候選，目前只憑紀錄能放進 `difference_interval` 的是零筆
- issue 的提議是例如 `signal_source` 欄位；名稱與位置由擁有者決定

修不掉的限制：配對紀錄不是 holdout

記下訓練與評估資料集的配對，只能描述關係，不能建立 holdout 。

`training_dataset_id` 與 `dataset_id`	能說明什麼
相等	只有後端用該 artifact 產生訊號時，才代表分數是樣本內
不相等	什麼都證明不了：身分也涵蓋期間與程式指紋，不同版本仍可能重疊
空值	未知，包括綁定出現之前寫入的所有紀錄

同理，用最佳化訓練 scope 建出的平台是樣本內。 #205 建議策略定案前保留最終評估資料。

目前不能說的事

- 統計模組**沒有**接入績效發佈、 MCP 結果查詢或排行榜
- main **沒有** `domain/statistics` ；本簡報引用的程式都在 PR 分支上
- `comparison` 與 `benchmark` **還沒有** PR
- `arch` 依賴只在 #209 加入， main 沒有

統計模組的定位

回答「這個結果可信到什麼程度」，不取代研究設計：
樣本外資料要事先保留，選擇的規模要事先記錄。

參考資料

- 系統架構（main `ad2fb75`） ・ #209 分支的版本
- 程式：`periods` ・ `breakeven` ・ `plateau` ・ `sharpe` ・ `performance` ・ `comparison` ・ `benchmark`
- 績效產物 ・ ML research
- PR：#205 ・ #206 ・ #207 ・ #208 ・ #209 ・ #38
- Issue：#189 ・ #190